



# IA GÉNÉRATIVES: DES OUTILS ET DES DÉFIS

Jeudi 10 avril 2025

Assemblée Générale d'AgroParisTech Alumni

Agros & IA : Regards croisés sur une révolution en marche

Vincent Guigue

<https://vguigue.github.io>



# Les modèles de langue en 5 tableaux

## Modélisation probabiliste de la langue

Découpage des textes = tokens

Large Language Models (LLMs), such as GPT-3 and GPT-4, utilize a process called tokenization. Tokenization involves breaking down text into smaller units, known as tokens, which the model can process and understand. These tokens can range from individual characters to entire words or even larger chunks, depending on the model. For GPT-3 and GPT-4, a Byte Pair Encoding (BPE) tokenizer is used. BPE is a subword tok

Itération du processus

Dictionnaire	Large entire For units ... can may ...	0.02 0.01 0.00 0.00 ...
		0.00 0.00 0.09 ...

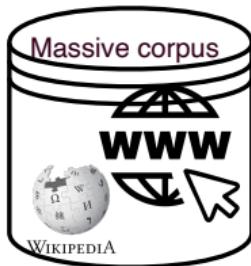
0.02
0.01
0.00
0.00
...
0.00
0.00
0.09
...
0.30

Début de texte

Modèle de langue

Prédiction de la suite

# Les modèles de langue en 5 tableaux



Pré-entraînement  
Compléter des phrases



1963, he was was assassinated in Dallas ...

Modèle de  
langue

JFK died in

**Acquisition de:**  
grammaire  
entités  
connaissances  
raisonnement (?)

# Les modèles de langue en 5 tableaux

## Instruction finetuning

Please answer the following question.

What is the boiling point of Nitrogen?

## Chain-of-thought finetuning

Answer the following question by reasoning step-by-step.

The cafeteria had 23 apples. If they used 20 for lunch and bought 6 more, how many apples do they have?



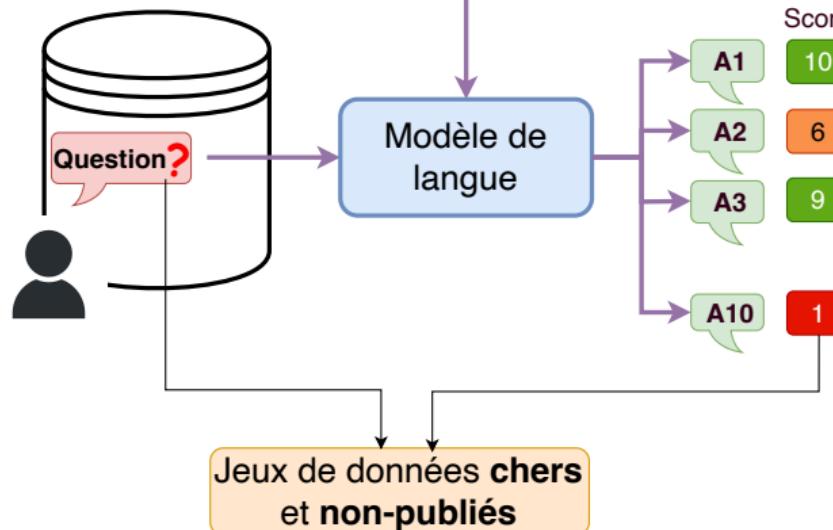
Spécialisation sur des tâches

Modèle de langue

Acquisition de:  
Capacité de répondre à une question  
Suivre un dialogue  
Connaissances physiques  
Bases de raisonnement

# Les modèles de langue en 5 tableaux

## Reinforcement Learning with Human Feedback



Reinforcement learning



Human Feedback

Score

10

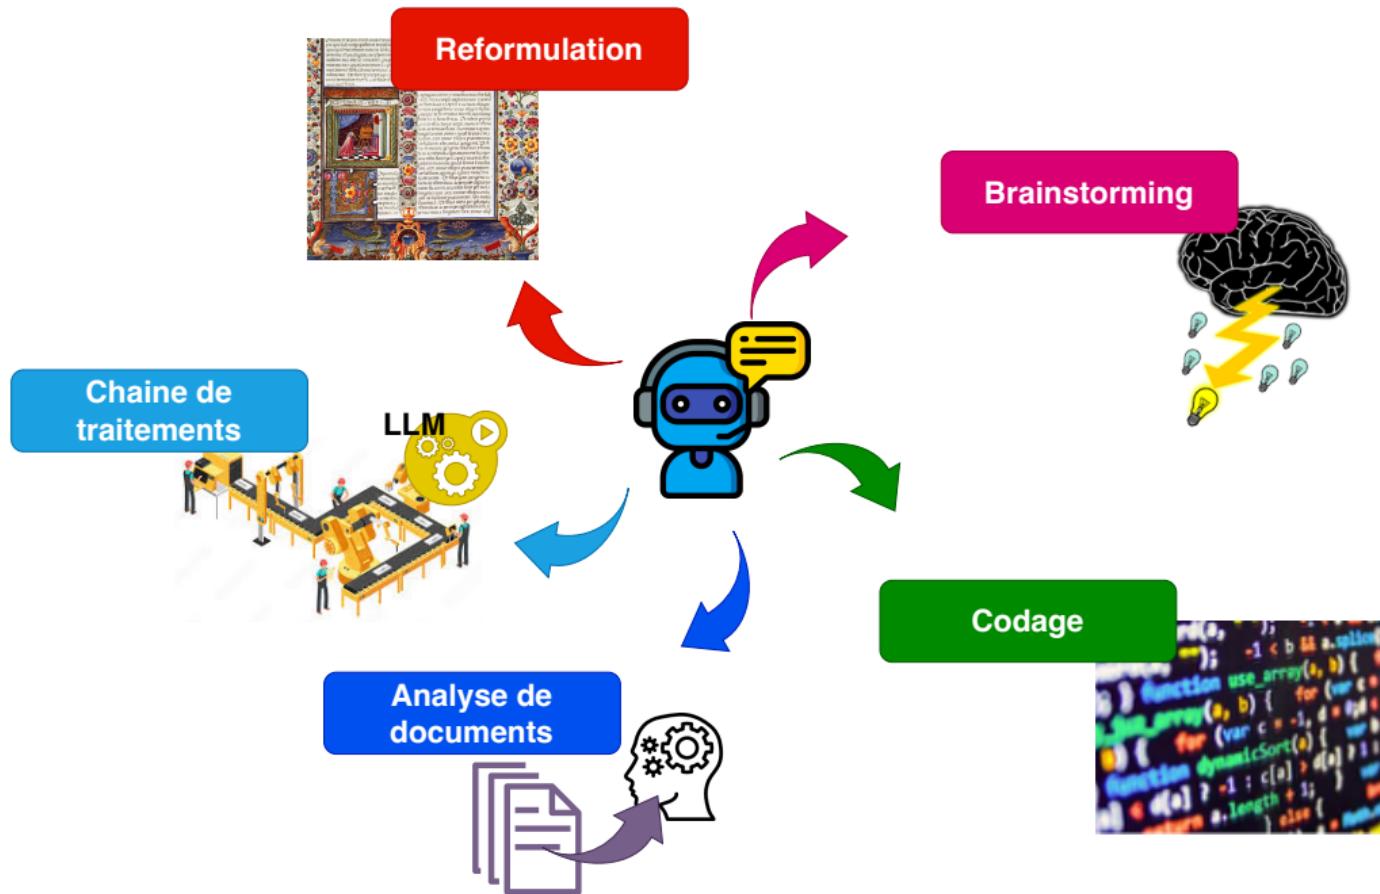
6

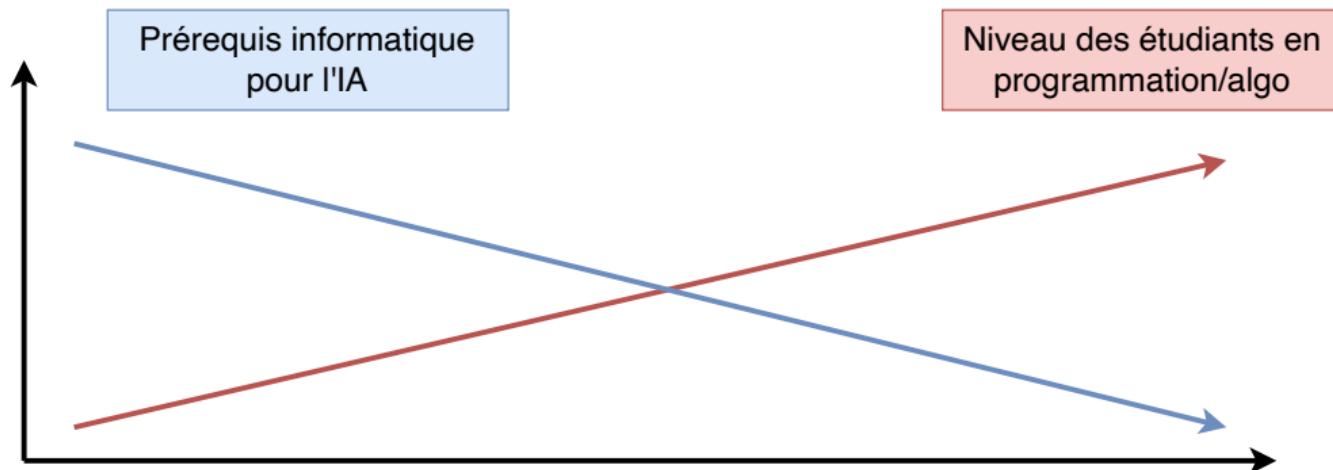
9

1

Apprentissage des préférences  
Censure  
Styles  
Qualité générale des résultats

# Les principaux usages en 5 tableaux





**1985-2005:** généralisation de l'enseignement de l'informatique dans l'ens. supérieur scientifique

**1995**  
numpy

**2002**  
torch

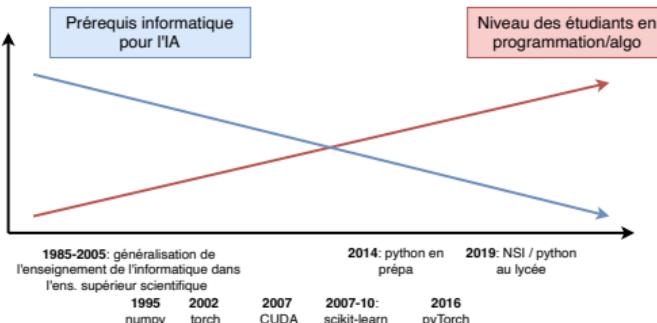
**2007**  
CUDA

**2007-10:**  
scikit-learn

**2016**  
pyTorch

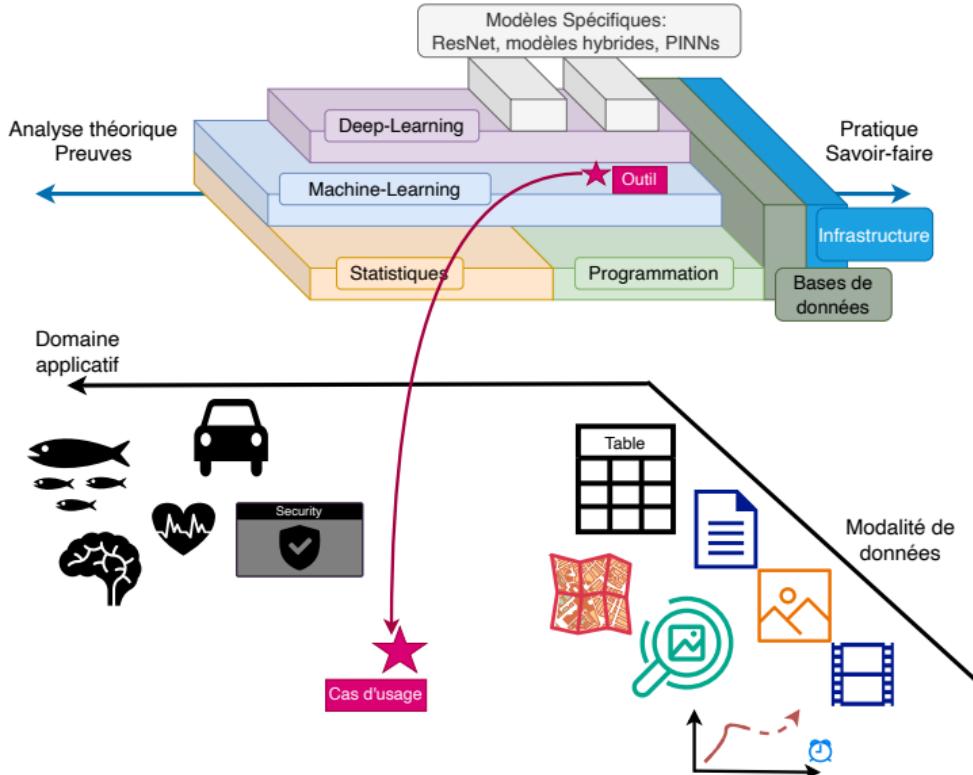
**2014:** python en prépa

**2019:** NSI / python au lycée

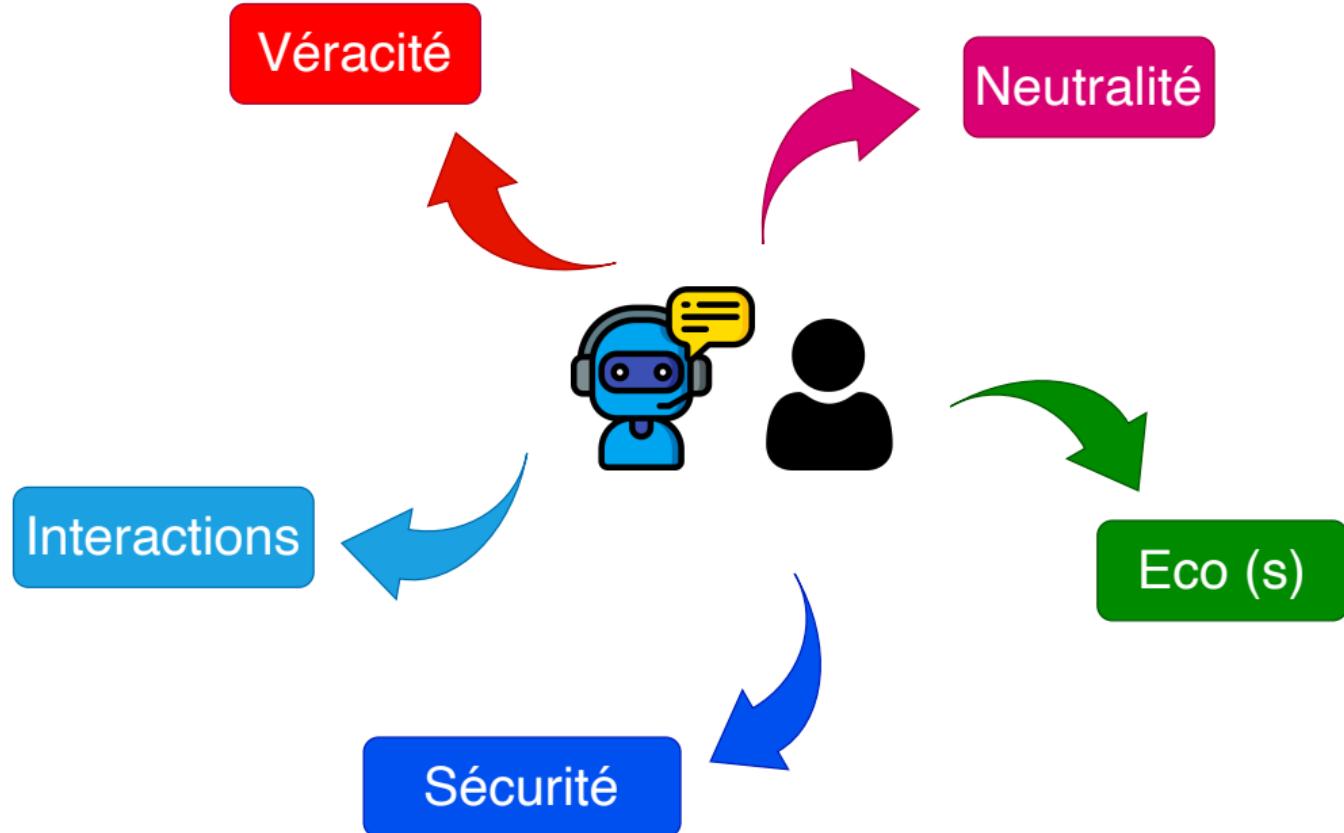


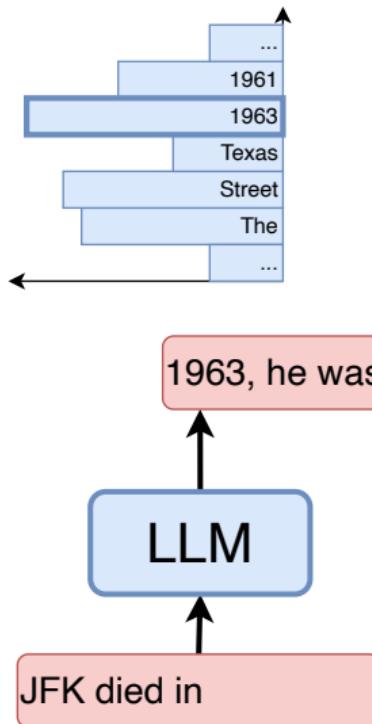
### 3 Niveaux d'accès à l'IA:

- **Exploiter** un chatbot... de manière **optimale & responsable**
- **Utiliser** les outils, manipuler des données
- **Développer** des outils



- 1A:** python + stats
- 2A:** mod. linéaires, machine learning
- 3A:** Spécialisation IODAA, deep learning, texte, image, bio-info





- Véracité  $\neq$  vraisemblance  
⇒ hallucinations

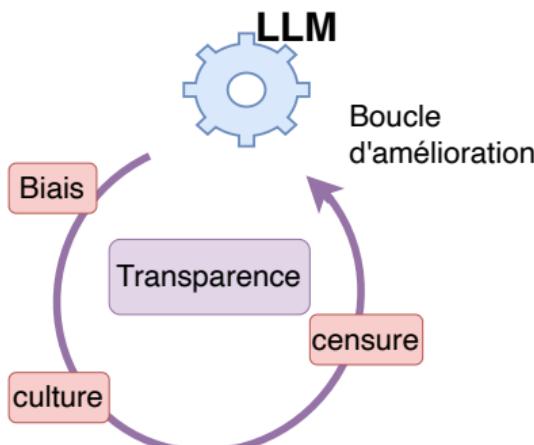
- Confiance / filtrage
- Stabilité
- Evaluation

\Leftrightarrow fréquence des informations:

- grammaire
- fait historique
- évènement ponctuel
- ...

# Les défis de l'IA: neutralité et transparence

- Sélection des données (sources, pondérations)
- Transformation des données (combinaison, filtrage)
- Architecture (coûts, optim., contraintes)
- Post-traitement (Alignment des LLMs)



Les biais des données sont amplifiés par les algos

≡ Google Traduction



Texte Images Documents Sites Web

Détecter la langue Anglais Français ↗ ↘ Français Anglais Arabe ↗

The nurse and the doctor

L'infirmière et le médecin

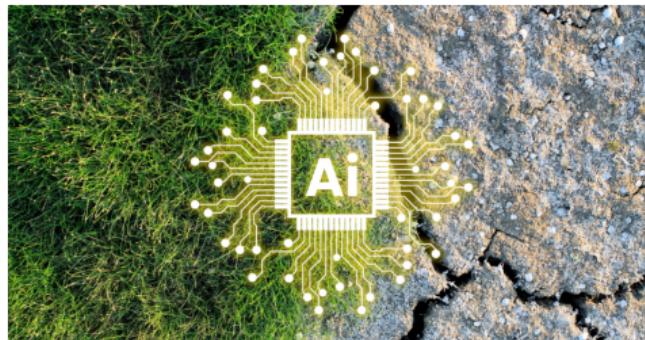
La censure / alignment... pose aussi des problèmes

Fabriquer une bombe...  
Apologie du nazisme...  
La terre est plate...  
Qui es-tu chatGPT...



## Ecologie

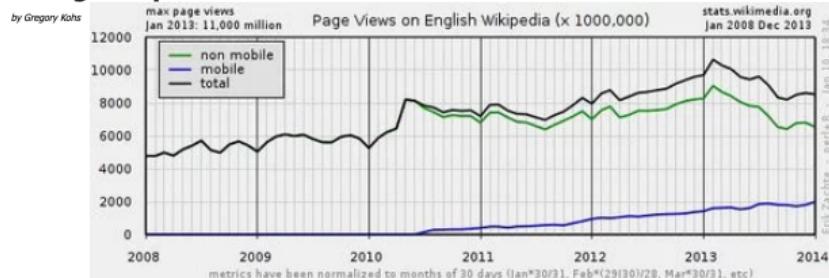
- Requête LLM =  $10/(100x)$  une requête Google
- Ratio coûts vs gains
- Risque du techno-solutionisme (agriculture de précision, puit carbone, ...)



## Economie

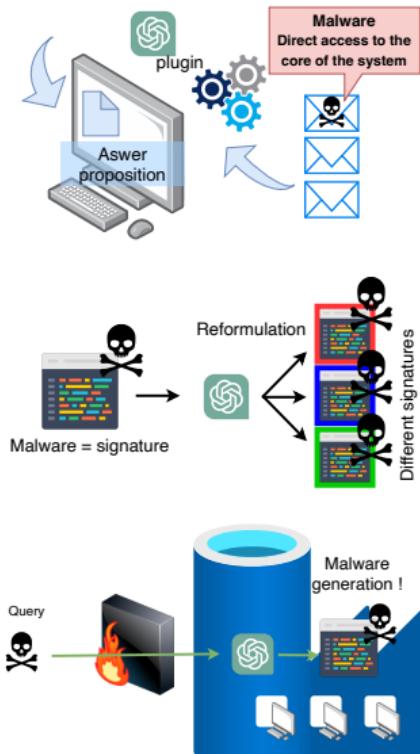
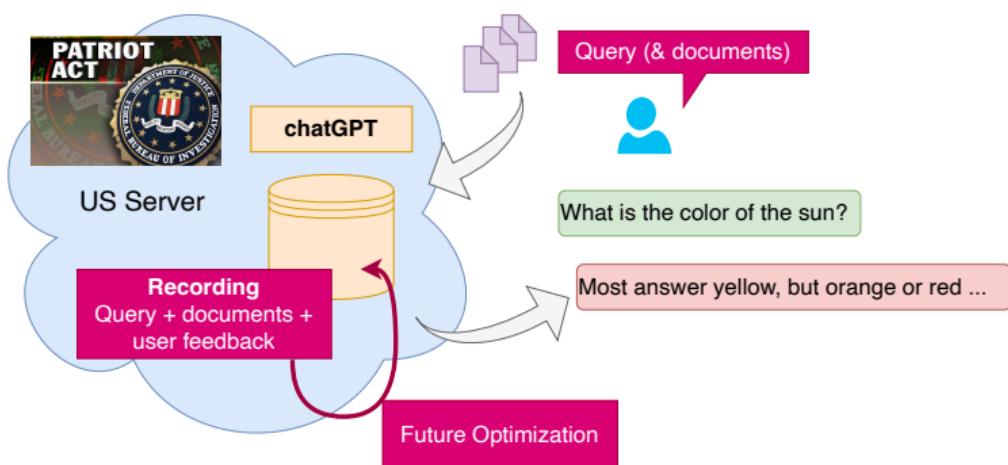
- Quel coût/souveraineté/perrenité pour les projets en IA?
- IA & fracture sociale: réduction ou augmentation?
- Quel modèle économique pour les producteurs de contenus?

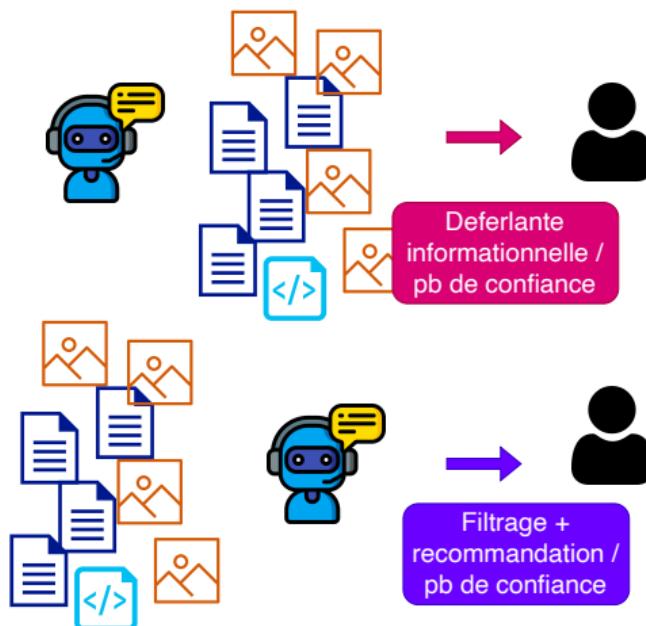
### Google's Knowledge Graph Boxes: killing Wikipedia?



# Les défis de l'IA: la sécurité et la vie privée

IA = (souvent) fuite de données





- Interface commerciale
- Interface RH
- Interface médicale
- Interface pédagogique
- Interface informationnelle

⇒ Des opportunités et des risques : biais, stigmatisation, inégalité de traitement, désinformation, harcèlement

## Des outils à double tranchant

L'humain augmenté... Mais au profit de qui?  
Quid du remplacement de l'homme par la machine?

## Médecine

- 1 Autonomie :** le patient doit pouvoir prendre des décisions éclairées.
- 2 Bienfaisance :** obligation de faire le bien, dans l'intérêt des patients.
- 3 Non-malfaisance :** éviter de causer du tort, évaluer les risques et les bénéfices.
- 4 Justice :** équité dans la distribution des ressources et des soins de santé.
- 5 Confidentialité :** confidentialité des informations des patients.
- 6 Vérité et transparence :** fournir une information honnête, complète et compréhensible.
- 7 Consentement éclairé :** obtenir le consentement libre et éclairé des patients.
- 8 Respect de la dignité humaine :** traiter tous les patients avec respect et dignité.

## Intelligence Artificielle

- 1 Autonomie :** les humains contrôlent le processus
- 2 Bienfaisance :** dans l'intérêt de qui ?  
Utilisateur + GAFAM...
- 3 Non-malfaisance :** humains + environnement / durabilité / usages malveillants
- 4 Justice :** accès à l'IA et égalité des chances
- 5 Confidentialité :** qu'en est-il du modèle économique de Google/Facebook ?
- 6 Vérité et transparence :** la tragédie de l'IA moderne
- 7 Consentement éclairé :** des cookies aux algorithmes, savoir quand on interagit avec une IA
- 8 Respect de la dignité humaine :** Alignement / censure nécessaire mais qui pose des questions

## Médecine

- 1 **Autonomie** : le patient doit pouvoir prendre des décisions éclairées.
- 2 **Bienfaisance** : obligation de faire le bien, dans l'intérêt des patients.
- 3 **Non-malfaisance** : éviter de causer du tort, évaluer les risques et les bénéfices.
- 4 **Justice** : équité dans la distribution des ressources et des soins de santé.
- 5 **Confidentialité** : confidentialité des informations des patients.
- 6 **Vérité et transparence** : fournir une information honnête, complète et compréhensible.
- 7 **Consentement éclairé** : obtenir le consentement libre et éclairé des patients.
- 8 **Respect de la dignité humaine** : traiter tous les patients avec respect et dignité.

## Intelligence Artificielle

- 1 **Autonomie** : les humains contrôlent le processus
- 2 **Bienfaisance** : dans l'intérêt de qui ? Utilisateur + GAFAM...
- 3 **Non-malfaisance** : humains + environnement / durabilité / usages malveillants
- 4 **Justice** : accès à l'IA et égalité des chances
- 5 **Confidentialité** : qu'en est-il du modèle économique de Google/Facebook ?
- 6 **Vérité et transparence** : la tragédie de l'IA moderne
- 7 **Consentement éclairé** : des cookies aux algorithmes, savoir quand on interagit avec une IA
- 8 **Respect de la dignité humaine** : Alignement / censure nécessaire mais qui pose des questions

