

Systeme multi-agents pour la génération de données d'entraînement pour le TableQA

Raphaël Mouravieff (1,7), Tanguy Herserant (1,2,7), Arthur Satouf (4,5,6,7), Habiboulaye Amadou Boubacar (4), Pablo Piantanida (5,6), Vincent Guigue (2,7), Sylvain Lamprier (3,7), Benjamin Piwowarski (1,7)

- (1) Sorbonne Université, CNRS, Paris
- (2) AgroParisTech - MIA, Palaiseau
- (3) Université Paris Cité, CNRS, LAMSADE, Paris
- (4) Air liquide
- (5) ILLS, MILA, Montreal, Canada
- (6) Centralesupelec, CNRS, Palaiseau
- (7) ISIR, Paris

TableQA litterature

Comment requêter une données textuelle sous forme tabulaire ?

Rank	City	Population	Department
1	Paris	2,187,526	Paris
2	Marseille	863,310	Bouches-du-Rhône
3	Lyon	516,092	Rhône
...	...	...	...
18	Angers	152,960	Maine-et-loire
19	Nîmes	150,610	Gard
20	Saint-Denis	147,931	La Réunion

INSEE POPULATION DATABASE

Question : Quelle est la ville qui a le plus d'habitants ?


Réponse : Paris

Problème : Accéder à des informations structurées à l'aide du langage naturel

Solution : modèle IA de Table QA

TAPEX - Etat de l'art

TAPEX (Liu et al. 2021) utilise des données de type template pour pre-entraîner le modèle



TableQA – Perturbation & capacité de généralisation

Des performances qui s’effondrent à la moindre perturbation

Original Quelle ville a la plus grande population ?

Perturbé Quelle ville compte le plus grand nombre d’habitants ?

Abbreviation

Synonyme

Original


Rank	Town	Pop
1	Paris	2,187,526
...	...	...
20	Saint-Denis	147,931

Rank	Town	Population
1	Paris	2,187,526
...	...	...
20	Saint-Denis	147,931

Rank	Town	Population
1	Paris	2,187,526
...	...	...
20	Saint-Denis	147,931


TableQA - benchmark RobuT (Zhao et al. 2023)

Des performances qui s'effondrent à la moindre perturbation




DQE - proposition

Des données générées grâce aux LLMs pour plus de diversité



DQE - Pipeline d'agents

Un pipeline de 3 agents appelés de façon séquentielle



Jeu de données, métrique et expérience



Jeu de données

RobuT

Benchmark de robustesse pour le Table QA :

Perturbations sur les colonnes

Reformulations de questions

Zhao et al., 2023



Métrique d'évaluation

Ratio de Robustesse

Mesure la **proportion de précision conservée** après perturbation :

Précision perturbée

Précision original

*Permet une comparaison équitable
entre les configurations.*



Paramètres d'expérience

Similaire à TAPEX

**La qualité des données
de pré-entraînement**

*Tout le reste est fixé — seul l'impact de nos
données générées est mesuré.*

Résultat sur la robustesse

Grâce au pré-apprentissage sur les données venant des agents IA, DQE est beaucoup moins sensible aux perturbations

Perturbation Type	TAPEX (%) Robustness Ratio	DQE (%) Robustness Ratio	Variation (DQE – TAPEX)
abbreviation (header)	92.2	98.0	+5.8
synonym (header)	91.1	99.4	+8.4
word (question)	89.4	93.1	+3.7
sentence (question)	90.8	91.2	+0.5
masked (content)	90.6	87.7	-2.9
column (content)	88.9	90.6	+1.6
add (content)	84.3	87.4	+3.1
row (content)	79.1	80.9	+1.8
combined	80.1	83.1	+3.0
extend (content)	73.5	73.3	-0.2

*DQE est **beaucoup moins sensible** aux perturbations,
en particulier **celles impliquant des variations sémantiques***

Explication des performances

L'explication peut s'expliquer grâce à la plus grande diversité de types de noeuds SQL

```
SELECT name FROM players WHERE age > 25 AND team = 'PSG'
```

Quand on passe cette requête dans sqlglot, on obtient un arbre comme ça :

```
Select
├── Column: name
│   └── Identifier: name
├── From
│   └── Table: players
│       └── Identifier: players
└── Where
    ├── And
    │   ├── GT (>)
    │   │   ├── Column: age
    │   │   │   └── Identifier: age
    │   │   └── Literal: 25
    │   └── EQ (=)
    │       ├── Column: team
    │       │   └── Identifier: team
    │       └── Literal: 'PSG'
```

Explication des performances

L'explication peut s'expliquer grâce à la plus grande diversité de types de noeuds SQL

Metric	DQE	TAPEX	Difference
Number of query	10,000	10,000	0
Unique Node Types	69	38	31
Total Node Count	185,550	77,260	108,290
Rare Node Types (≥ 10)	12	6	6
Common Node Types	35	35	0
Exclusive Node Types	34	3	31

Comparaison des statistiques des graphes SQL entre notre jeu de données généré et TAPEX

Conclusion

DQE est une méthode permettant de générer des données d'adaptation de domaine plus diversifiées et de bien meilleure qualité

Bilan

La collaboration multi-agents génère des **données d'adaptation plus diversifiées**.

Augmentation démontrée de la robustesse face aux perturbations

Perspectives

Ablation

Isoler l'impact exact de chaque agent (Curriculum, Traducteur, Diversifieur)

Mise à l'échelle

Étendre la durée d'entraînement pour mesurer la limite des gains de robustesse

Le point de bascule

Déterminer le seuil où une diversité excessive devient contre-productive (bruit)